

2º SEMESTRE – CHALLENGE SPRINT 3

Integrantes:

- Natan Silva da Costa – RM 573100
- Leonardo Scotti Tobias – RM 573305
- Luca Almeida Lucareli – RM 569061
- Henrique Almeida Lucareli – RM 569183
- Enzo Seiji Delgado Tabuchi – RM 573156

Base de Dados: smart_home_energy_consumption_large.csv (mesma base utilizada na Sprint 2).

Variável Seleccionada para Análise (Distribuição Normal): Energy Consumption (kWh)

Variáveis Seleccionadas para Regressão: X = Outdoor Temperature (°C) | Y = Energy Consumption (kWh)

01) Probabilidade Acima da Mediana

- **a) Cálculo da mediana:** A mediana encontrada para a variável *Energy Consumption (kWh)* foi de **1.2300 kWh**.
- **b) Cálculo da probabilidade:** Assumindo que a variável segue uma Distribuição Normal $P(X > \text{Mediana})$, a probabilidade calculada via CDF (Função de Distribuição Acumulada) de um valor ser superior à mediana é de **0.5904 (59,04%)**.
- **c) Código estruturado:** O código Python em anexo (.py) demonstra o uso das bibliotecas pandas e scipy.stats (função norm.cdf) para o cálculo.
- **d) Classificação do evento:** Com uma probabilidade de 59,04%, o evento é classificado como **Provável** (situando-se na faixa > 0.30 e ≤ 0.70).

02) Probabilidade dentro do intervalo (Média $\pm 2s$)


- **a) Cálculo dos parâmetros estatísticos:**
 - Média (μ): **1.5000 kWh**
 - Desvio Padrão (s): **1.1812 kWh**
 - Intervalo Calculado ($\mu - 2s$ até $\mu + 2s$): **[-0.8624, 3.8623]**
- **b) Cálculo da probabilidade:** A probabilidade de o consumo de energia se encontrar

dentro deste intervalo de dois desvios padrões é de **0.9545 (95,45%)**.

- **c) Código estruturado:** A execução ocorreu sem erros através do cálculo de área sob a curva normal ($\text{prob_superior} - \text{prob_inferior}$) via código .py anexo.
- **d) Classificação do evento:** Devido à altíssima probabilidade (95,45%), típica da Regra Empírica da distribuição normal, o evento é classificado como **Quase Certo**.

03) Modelagem com Regressão Linear

- **a) Código Correto:** O modelo de regressão linear simples foi instanciado e treinado utilizando scikit-learn (código anexo).
- **b) Gráfico da reta ajustada:**



- **c) Interpretação dos coeficientes da regressão:**
 - **Coefficiente Linear (Intercepto = 14.9136):** Em um cenário teórico onde a temperatura externa (Outdoor Temperature) fosse 0°C, o modelo prevê que o consumo de energia basal seria de 14.9136 kWh. Este valor atua como o ponto de partida da nossa reta no eixo Y.
 - **Coefficiente Angular (Inclinação = 0.0244):** Este valor representa a taxa de variação. Ele indica que, para cada aumento de 1°C na temperatura externa, o consumo de energia aumenta minimamente em 0.0244 kWh. Como o valor é muito próximo de zero, a inclinação da reta é quase nula (horizontal), indicando uma correlação linear extremamente fraca entre temperatura e consumo na base

analisada.

04) Organização, clareza e interpretação geral

- **b) Interpretação geral relacionando Estatística e Aprendizado de Máquina:**

A execução deste laboratório evidencia que o **Aprendizado de Máquina supervisionado** é estritamente dependente da validação **Estatística**.

Estatisticamente, nossa análise de Distribuição Normal (exercícios 1 e 2) comprovou a Regra Empírica dos 95,45% em um intervalo de ± 2 desvios padrões. Contudo, ao observar a regressão gerada pela máquina, notamos um comportamento estatístico peculiar: a falta de correlação expressiva entre as variáveis independentes e dependentes (coeficiente angular tendendo a zero de 0.0244).

Do ponto de vista do Aprendizado de Máquina, o modelo fez o que foi instruído através do Método dos Mínimos Quadrados (OLS), traçando uma reta de previsão de consumo elétrico. No entanto, a Estatística nos revela que esses dados específicos geram um modelo preditivo fraco (ruído), pois a dispersão dos dados assemelha-se a uma Distribuição Uniforme em bloco.

Isso nos ensina a lição mais valiosa da ciência de dados: um algoritmo de *Machine Learning* sempre gerará uma reta e calculará probabilidades se for programado para isso, mas cabe ao ser humano, com o rigor da *Estatística*, interpretar os coeficientes (inclinação nula) para perceber que as variáveis da base atual não explicam a variância umas das outras de forma confiável para predições de negócio reais.